MDPI

Artículo

Predicción de la mortalidad materna hospitalaria y de la morbilidad materna grave en MIMIC-IV mediante un ensamble apilado de aprendizaje automático bajo desbalance extremo de clases

Emmanuel Gutiérrez Jiménez [1,*] 0009-0005-2358-4680 y José Duván Márquez Díaz [2] 0000-0003-0400-5020

[1] Departamento de Ingeniería de Sistemas, Universidad del Norte, Barranquilla 081007, Colombia; emmanuelg@uninorte.edu.co
[2] Departamento de Ingeniería de Sistemas, Universidad del Norte, Barranquilla 081007, Colombia; jmarquez@uninorte.edu.co
* Correspondencia: emmanuelg@uninorte.edu.co; Tel.: +57-310-432-6347

Puntos destacados

¿Cuáles son los principales hallazgos?

- La muerte materna es demasiado infrecuente en MIMIC-IV para modelarla de forma confiable (41 de 25,736 ingresos obstétricos, 0.16%): el AUC del ensamble apilado con validación cruzada de cinco particiones fue 0.853 ± 0.078, pero la precisión promedio fue de solo 0.164 ± 0.090.
- Usar la morbilidad materna grave (MMG; 475 positivos, 1.85%) como desenlace produjo una tarea notablemente más estable: en un conjunto de prueba independiente el ensamble apilado alcanzó un AUC de 0.913 y una precisión promedio de 0.384 (unas 21 veces la prevalencia), con una sensibilidad de 0.79; la validación cruzada lo confirmó (AUC 0.904 ± 0.020, AP 0.419 ± 0.050). Marcar el 5% superior de los ingresos capturó el 68% de los casos de MMG.

¿Cuáles son las implicaciones de los principales hallazgos?

- En datos de un solo centro, la MMG es un objetivo de modelamiento más adecuado que la mortalidad para la predicción del riesgo materno; las estimaciones puntuales de mortalidad no deben sobreinterpretarse.
- Retirar los indicadores de grupos diagnósticos del modelo de mortalidad redujo su AUC con validación cruzada de 0.853 a 0.690, y las probabilidades predichas no estuvieron calibradas: los modelos deben usarse para ordenar ingresos, no para estimar el riesgo absoluto.
- El sobremuestreo (SMOTE) no mejoró las métricas basadas en precisión, y la winsorización de valores atípicos evitó descartar el 19.5% de las muertes y el 38.7% de los casos de MMG que la eliminación de filas habría removido.

Recibido:
Revisado:
Aceptado:
Published:

Copyright: © 2026 by the authors. Submitted to *Healthcare* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license.

Resumen

Antecedentes: La mortalidad materna sigue siendo una prioridad mundial de salud, pero las muertes son tan infrecuentes en datos de un solo centro que la evaluación estándar del aprendizaje automático (AA) resulta poco confiable. La morbilidad materna grave (MMG; *severe maternal morbidity*, SMM, en inglés), definida mediante indicadores de diagnósticos y procedimientos de los CDC/HRSA, es aproximadamente cien veces más frecuente y se emplea ampliamente como aproximación al *near miss*. **Métodos**: Se construyeron dos modelos con la base de datos de historias clínicas electrónicas MIMIC-IV a partir de

25,736 ingresos hospitalarios obstétricos de mujeres de 12 a 55 años (rango observado: 18 a 55): el Modelo A (muerte registrada durante el ingreso índice o posteriormente; 41 eventos, 0.159%) y el Modelo B (al menos uno de los 20 indicadores de MMG de la FAD-2023 de CDC/HRSA; 475 eventos, 1.846%). El flujo de trabajo incluyó limpieza de valores centinela y ceros implausibles, winsorización por rango intercuartílico (RIC$\times$3) en lugar de eliminación de filas, imputación guiada por la asimetría, escalado diferenciado e indicadores de diagnóstico agrupados por expertos (usados únicamente en el Modelo A para evitar fuga de información del desenlace en el Modelo B). Se ajustaron Random Forest, XGBoost, Extra Trees, regresión logística y un ensamble apilado mediante búsqueda en malla con validación cruzada sobre la precisión promedio. La validación cruzada estratificada de cinco particiones fue la evidencia principal para el Modelo A y complementó la evaluación en el conjunto de prueba del Modelo B; se añadieron como análisis adicionales SMOTE, un análisis del Modelo A sin grupos diagnósticos, la calibración fuera de partición con bandas de riesgo, los valores SHAP y una auditoría por subgrupos. **Resultados**: Para el Modelo A, el ensamble apilado alcanzó un AUC con validación cruzada de 0.853 $\pm$ 0.078 y una precisión promedio (AP) de 0.164 $\pm$ 0.090 (prevalencia 0.0016); el conjunto de prueba contenía solo ocho muertes. Para el Modelo B, el ensamble apilado obtuvo el mejor AUC (0.913) y AP (0.384; prevalencia 0.018) en el conjunto de prueba, con sensibilidad de 0.79 y precisión de 0.14 con el umbral predeterminado; restringido a hospitalizaciones por parto, la AP fue 0.646. La validación cruzada dio un AUC de 0.904 $\pm$ 0.020 y una AP de 0.419 $\pm$ 0.050 para el Modelo B, y marcar el 5% superior de los ingresos capturó el 68% de los casos (valor predictivo positivo 0.25). Retirar los grupos diagnósticos redujo el AUC con validación cruzada del Modelo A de 0.853 a 0.690, las probabilidades predichas no estuvieron calibradas (media 0.249 frente a una prevalencia de 0.018) y, en la auditoría por subgrupos, el AUC fue menor entre los ingresos con estancia en UCI (0.655). SMOTE no mejoró la AP. **Conclusiones**: En esta cohorte de un solo centro, la MMG permite una evaluación de AA considerablemente más estable que la mortalidad. Los resultados siguen siendo exploratorios, porque la etiqueta de MMG se basa en códigos CIE, los datos provienen de una sola institución y no se realizó validación externa.

Palabras clave: mortalidad materna; morbilidad materna grave; *near miss*; MIMIC-IV; ensamble apilado; desbalance de clases; precisión–sensibilidad; aprendizaje automático; historias clínicas electrónicas

1. Introducción

La mortalidad materna sigue siendo un problema importante de salud pública: la Organización Mundial de la Salud y sus organismos aliados estimaron cerca de 287,000 muertes maternas en el mundo en 2020 [1]; los análisis de carga global siguen la mortalidad materna a lo largo del tiempo y entre regiones [2], y un análisis sistemático de la OMS ha descrito sus principales causas [3]. Sin embargo, en hospitales de altos recursos la muerte materna es un evento muy infrecuente. Esta rareza constituye un obstáculo estadístico para el aprendizaje supervisado: con una prevalencia de unos pocos casos por mil ingresos, cada partición de validación cruzada y cada conjunto de prueba contienen apenas un puñado de positivos, de modo que un solo paciente mal clasificado puede modificar la sensibilidad en varios puntos porcentuales, y la exactitud y el AUC-ROC por sí solos dejan de ser informativos [4,5].

Una forma ampliamente utilizada de mitigar este problema es modelar la *morbilidad materna grave* (MMG; SMM en inglés), o *near miss* [6], como desenlace sustituto. Los Centros para el Control y la Prevención de Enfermedades de Estados Unidos (CDC) definen la MMG

mediante un conjunto de indicadores de diagnósticos CIE-10-CM y de procedimientos CIE-10-PCS, que la Administración de Recursos y Servicios de Salud (HRSA) distribuye en su documento de recursos de datos federalmente disponibles (FAD) [7,8]. Los eventos de MMG ocurren aproximadamente cien veces más a menudo que las muertes maternas hospitalarias entre las hospitalizaciones por parto y posparto [9], y se ha mostrado que los códigos diagnósticos administrativos contienen información pronóstica sobre la morbilidad materna [10]. La contrapartida es la calidad de la etiqueta: una validación frente a la revisión de historias clínicas en un hospital público reportó baja sensibilidad y bajo valor predictivo positivo para la identificación de MMG basada en CIE-10 [11].

La base de datos MIMIC-IV, del Beth Israel Deaconess Medical Center y sucesora de MIMIC-III [12], ofrece registros hospitalarios anonimizados con resultados de laboratorio, signos vitales registrados y códigos diagnósticos [13,14]. Aunque MIMIC-IV no es una base de datos obstétrica, contiene miles de ingresos de mujeres con diagnósticos relacionados con el embarazo, lo que permite una comparación reproducible de las dos definiciones de desenlace sobre las mismas pacientes y los mismos predictores.

El apilamiento de ensambles (*stacking*) combina aprendices base heterogéneos mediante un metaaprendiz y con frecuencia supera a sus componentes [15,16]. Si esta ventaja persiste bajo un desbalance extremo, y si remedios habituales como el sobremuestreo ayudan [17], es una cuestión empírica. Este estudio hace, por tanto, las siguientes contribuciones:

- Una comparación lado a lado de dos desenlaces en una misma cohorte obstétrica de 25,736 ingresos de MIMIC-IV: la muerte materna registrada en el ámbito hospitalario (Modelo A) y la MMG definida por CDC/HRSA (Modelo B).
- Un protocolo de evaluación consciente del desbalance: análisis ROC y de precisión–sensibilidad basado en probabilidades, precisión promedio como criterio de ajuste, validación cruzada estratificada como evidencia principal para el desenlace más infrecuente y un análisis de sensibilidad explícito con SMOTE.
- Control explícito de la fuga de información para la MMG: los indicadores de grupos diagnósticos derivados de los mismos códigos CIE que definen el desenlace se excluyen del Modelo B, y un análisis de sensibilidad restringe la evaluación a las hospitalizaciones por parto (el denominador comparable con los CDC).
- Una política de valores atípicos basada en winsorización que conserva todos los casos positivos.

El resto del artículo se organiza como sigue. La Sección 2 revisa los trabajos relacionados, la Sección 3 describe los datos y los métodos, la Sección 4 presenta los resultados, la Sección 5 discute los hallazgos y las limitaciones, la Sección 6 considera las implicaciones y el trabajo futuro, y la Sección 7 concluye.

2. Trabajos relacionados

2.1. Aprendizaje automático para la morbilidad y mortalidad maternas

Una revisión exploratoria de 39 estudios que aplicaron aprendizaje automático a datos de historias clínicas electrónicas para predecir morbilidad y mortalidad maternas encontró que los métodos de *boosting* fueron el enfoque más utilizado (18 estudios), que los desenlaces cardiovasculares e hipertensivos, la diabetes gestacional y la hemorragia posparto fueron los objetivos más comunes, que muchos estudios carecían de validación externa o de análisis de sensibilidad, que solo seis siguieron una guía de reporte y que ninguno describió cómo se aplicaron los modelos en la práctica clínica [18]. La muerte materna rara vez es el desenlace modelado, y la predicción de desenlaces perinatales ha sido revisada por separado por los autores [19].

2.2. Predicción de la morbilidad materna grave

Los estudios sobre MMG son más numerosos porque el desenlace es más frecuente. Gao et al. desarrollaron un marco que identificó la MMG y sus factores de riesgo a partir de las historias clínicas electrónicas de 45,858 partos en un centro médico académico; reportó un AUC de 0.94 frente a 0.80 de un modelo basado en los CDC, y puso de manifiesto indicadores como alteraciones electrolíticas, síndromes de respuesta inflamatoria y trastornos ácido–base que no forman parte de la definición de los CDC [20]. Li et al. predijeron la MMG definida por los CDC en 261,226 hospitalizaciones por parto en Maryland (1,976 eventos; 76 por 10,000 partos) con regresión logística y LASSO, utilizando datos vinculados de egresos hospitalarios y de encuestas hospitalarias; el mejor modelo, un LASSO con 18 variables, alcanzó un AUC con validación cruzada de 0.796 con baja sensibilidad en todos los modelos, y los autores reportaron un riesgo no ajustado aproximadamente el doble para mujeres negras no hispanas en comparación con mujeres blancas no hispanas. Señalaron el desbalance de clases y la falta de validación externa como limitaciones y propusieron técnicas de sobremuestreo como SMOTE como trabajo futuro [21]. También se ha mostrado que los códigos diagnósticos registrados durante el control prenatal contienen información pronóstica sobre la morbilidad materna [10].

2.3. Calidad de la etiqueta y metodología para eventos raros

La confiabilidad de las etiquetas de MMG es una preocupación reconocida: la identificación basada en CIE-10 se comparó con la revisión de historias clínicas en un hospital público y mostró baja sensibilidad y bajo valor predictivo positivo [11]. Al mismo tiempo, la MMG ocurre aproximadamente cien veces más a menudo que la muerte materna hospitalaria [9], lo que la convierte en el sustituto habitual cuando las muertes son demasiado pocas para modelarlas. El trabajo metodológico sobre eventos raros advierte que la exactitud y el AUC-ROC pueden ser poco informativos y que son preferibles el análisis de precisión–sensibilidad y el reporte explícito de la incertidumbre [4,5], y que las correcciones del desbalance pueden perjudicar la calibración sin mejorar la discriminación [17].

2.4. Posicionamiento de este estudio

Frente a los estudios anteriores, el presente trabajo se diferencia en cuatro aspectos. Primero, utiliza como predictores signos vitales al ingreso y valores de laboratorio de todo el hospital provenientes de MIMIC-IV, en lugar de datos de reclamaciones o de egresos. Segundo, modela la mortalidad y la MMG sobre los *mismos* 25,736 ingresos obstétricos con los mismos predictores y el mismo flujo de trabajo, lo que permite una comparación directa de las dos definiciones de desenlace. Tercero, controla explícitamente la fuga de información del desenlace y reporta un análisis de sensibilidad solo de partos comparable con los CDC. Cuarto, evalúa el remedio de sobremuestreo que Li et al. dejaron como trabajo futuro [21], utilizando SMOTE estrictamente dentro de las particiones de validación cruzada.

3. Materiales y métodos

3.1. Fuente de datos y cohorte de estudio

Se utilizó MIMIC-IV alojada en PostgreSQL [13] ([**PENDIENTE:** indicar la versión exacta de MIMIC-IV, p. ej., v2.2 o v3.1, y la fecha de acceso a PhysioNet]). La cohorte de estudio comprende ingresos hospitalarios de mujeres de 12 a 55 años (el rango observado fue de 18 a 55 años) con al menos un diagnóstico CIE obstétrico o relacionado con el embarazo (posición del diagnóstico ≤ 4), identificados mediante un universo diagnóstico ampliado que combina la búsqueda de texto en los títulos largos de CIE con rangos de códigos CIE. *No* se exigió una estancia en la unidad de cuidados intensivos (UCI): esto

es importante porque 30 de las 41 muertes registradas (73%) ocurrieron en ingresos sin ninguna estancia en UCI. La cohorte final contiene 25,736 ingresos, de los cuales 8,857 se identificaron como hospitalizaciones por parto. La Figura 1 resume el flujo de trabajo.

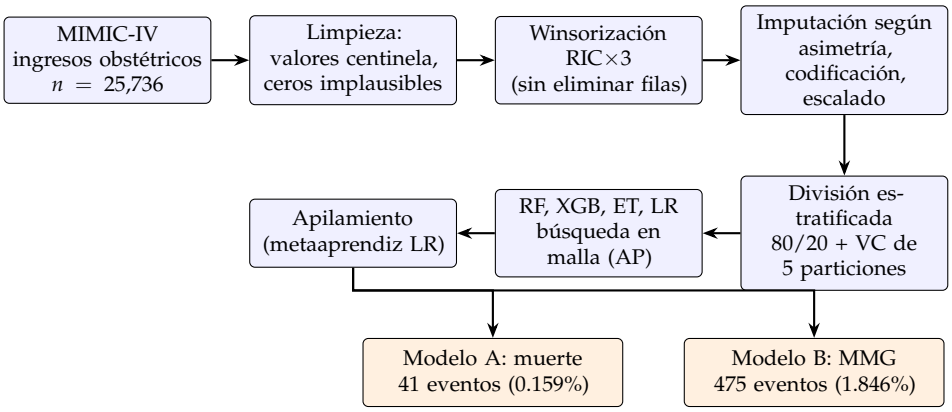


Figura 1. Visión general del flujo de trabajo. Se aplican los mismos pasos de limpieza, preprocesamiento y aprendizaje a ambos desenlaces. VC: validación cruzada.

3.2. Definiciones de los desenlaces

Modelo A (mortalidad). El desenlace es 1 si se registró una hora de muerte hospitalaria durante el ingreso índice o en cualquier ingreso posterior de la misma paciente, y 0 en caso contrario. Esto produjo 41 eventos entre 25,736 ingresos (0.159%).

Modelo B (MMG). Un ingreso es positivo para MMG si presenta al menos un código de diagnóstico CIE-10-CM o de procedimiento CIE-10-PCS que coincida con alguno de los 20 indicadores vigentes de la FAD-2023 de CDC/HRSA [7,8,22] (se excluye el antiguo indicador de transfusión de hemoderivados, retirado por la HRSA en 2023). Los indicadores se agrupan en siete categorías clínicas (cardiaca, renal, respiratoria, hemorragia, sepsis, otras obstétricas y otras médicas). Hubo 475 ingresos positivos para MMG (1.846%); entre las 8,857 hospitalizaciones por parto, 252 fueron positivas (2.845%, es decir, 284.5 por 10,000), por encima del rango de referencia publicado de 58–88 por 10,000 partos [22]. La mayor tasa es esperable, pues MIMIC-IV es un centro de referencia terciario y el denominador ampliado incluye también ingresos que no son partos. Los indicadores más frecuentes fueron insuficiencia renal aguda (180 ingresos), choque (72), SDRA (66), sepsis (62) y coagulación intravascular diseminada (61); el 23.4% de los ingresos positivos cumplió indicadores de más de una categoría clínica.

3.3. Predictores y preprocesamiento

Los predictores candidatos comprendieron variables administrativas (edad al ingreso, grupo étnico, seguro de salud, grupo de idioma, tipo de ingreso, lugar de ingreso, estancia en UCI y número de estancias en UCI) y el valor más temprano disponible de 27 variables de registro/laboratorio (signos vitales, componentes de la escala de coma de Glasgow, hematología y química). Para las 13 variables de laboratorio, los valores se tomaron también de los eventos de laboratorio de todo el hospital (no solo de los eventos registrados en UCI), lo cual es relevante aquí porque la mayoría de las muertes ocurrió fuera de la UCI. Los pasos de preprocesamiento fueron:

1. **Valores centinela y ceros implausibles.** El marcador 999,999 y los ceros fisiológicamente imposibles se establecieron como faltantes.
2. **Manejo de valores atípicos mediante winsorización.** Para cada variable continua, los valores más allá de $Q_1 - 3\,\mathrm{RIC}$ o $Q_3 + 3\,\mathrm{RIC}$ se recortaron al límite más cercano (con cotas inferiores clínicas), de modo que ningún ingreso se elimina. Las escalas ordinales y las variables con $\mathrm{RIC} = 0$ no se recortaron. Nuestra primera implementación

eliminaba las filas con valores fuera de los límites, como en nuestro flujo de trabajo neonatal previo; una auditoría mostró que esto removía 8 de 41 muertes (19.5%) en el Modelo A y 184 de 475 casos de MMG (38.7%) en el Modelo B, por lo que se reemplazó por la winsorización.

3. **Imputación.** Mediana para variables con $|\text{asimetría}| > 1$, moda en caso contrario.
4. **Codificación y escalado.** Codificación *one-hot* de los cinco grupos categóricos; `RobustScaler` para variables con $|\text{asimetría}| > 1$ y `MinMaxScaler` en caso contrario. Las variables de monitoreo en UCI casi constantes (componente motor de la escala de Glasgow y Escala de Agitación–Sedación de Richmond; el valor más frecuente cubría más del 99% de las filas) se descartaron del Modelo A.

Indicadores de grupos diagnósticos y control de fuga de información. Los códigos diagnósticos CIE de la cohorte (4,116 códigos distintos para el Modelo A) se agregaron en 26 indicadores binarios de grupos diagnósticos (`gdg_m01`–`gdg_m26`) según una clasificación clínica ([**PENDIENTE:** describir el procedimiento de clasificación y la composición del panel, o indicar que lo realizaron los autores]). Otros dos indicadores reservados para agrupamiento residual eran constantes y se eliminaron. Dado que estos indicadores se derivan de los mismos diagnósticos codificados que definen la MMG, se *excluyeron* del Modelo B; asimismo, los siete conteos de MMG por categoría, la etiqueta multiclase y la bandera de hospitalización por parto no se usaron como predictores (esta última se conserva únicamente para definir el subconjunto de evaluación). El Modelo A conservó los 26 indicadores, para un total de 89 predictores; el Modelo B utilizó 65 predictores. Esta diferencia entre los conjuntos de predictores se considera en la Sección 5.

La Tabla 1 enumera los 26 grupos diagnósticos. De los 4,116 códigos CIE distintos observados en la cohorte (2,192 CIE-10 y 1,924 CIE-9), 4,010 se asignaron a uno de los 26 grupos y 106 se excluyeron de la agrupación; doce grupos son obstétricos y catorce abarcan afecciones no obstétricas. Un paso de k-medias destinado a agrupar los códigos residuales no asignados no encontró códigos residuales, por lo que los dos indicadores de conglomerado reservados eran constantes y se eliminaron.

Tabla 1. Grupos diagnósticos utilizados como indicadores binarios en el Modelo A: descripción, si el grupo es obstétrico y número de códigos CIE distintos asignados.

Indicador	Grupo	Obstétrico	Códigos CIE
gdg_m01	Complicaciones del trabajo de parto y del parto	Sí	225
gdg_m02	Afección preexistente que complica el embarazo	Sí	167
gdg_m03	Trastornos hipertensivos del embarazo	Sí	95
gdg_m04	Otros trastornos maternos relacionados con el embarazo	Sí	83
gdg_m05	Complicaciones fetales / gestación múltiple	Sí	156
gdg_m06	Otras complicaciones puerperales	Sí	27
gdg_m07	Trastornos de la placenta / del líquido amniótico	Sí	43
gdg_m08	Hemorragia (anteparto/posparto)	Sí	57
gdg_m09	Infección (obstétrica/puerperal)	Sí	117
gdg_m10	Trabajo de parto pretérmino / rotura prematura de membranas	Sí	35
gdg_m11	Aborto / embarazo ectópico o molar	Sí	103
gdg_m12	Trastornos venosos / tromboembólicos	Sí	50
gdg_m13	Neoplasias	No	95
gdg_m14	Enfermedades digestivas	No	248
gdg_m15	Trastornos endocrinos / metabólicos / nutricionales	No	197
gdg_m16	Enfermedades cardiovasculares	No	231
gdg_m17	Trastornos del sistema nervioso	No	147
gdg_m18	Enfermedades de la sangre / del sistema inmunitario	No	107
gdg_m19	Enfermedades genitourinarias (no obstétricas)	No	175
gdg_m20	Enfermedades respiratorias	No	106
gdg_m21	Factores administrativos / contacto con los servicios de salud	No	306
gdg_m22	Síntomas, signos y hallazgos mal definidos	No	208
gdg_m23	Enfermedades infecciosas y parasitarias	No	147
gdg_m24	Traumatismos, envenenamientos y causas externas	No	355
gdg_m25	Otras comorbilidades menores	No	332
gdg_m26	Trastornos mentales y del comportamiento	No	198

3.4. Análisis de correlación

La colinealidad se revisó en dos pasos: un mapa de calor de todas las variables clínicas continuas y una revisión específica de los indicadores diagnósticos binarios, usando $|r| \geq 0.70$ como umbral para un par fuertemente correlacionado. Dado que los aprendices basados en árboles evalúan las variables de forma independiente en cada división y que la regresión logística está regularizada con L2, se conservaron todas las variables correlacionadas, ya que eliminar un miembro de una medición fisiológicamente pareada descartaría señal monitorizada de forma independiente sin un beneficio de modelamiento.

3.5. Algoritmos de aprendizaje y evaluación

Se entrenaron Random Forest (RF), XGBoost (XGB), Extra Trees (ET) y regresión logística (LR) con regularización L2 sobre una división estratificada 80/20 (semilla aleatoria 42): 20,588 ingresos de entrenamiento y 5,148 de prueba, con 33 y 8 muertes en el Modelo A y 380 y 95 casos de MMG en el Modelo B. El desbalance se manejó mediante ponderación de clases (`balanced` o `balanced_subsample`; `scale_pos_weight` de XGB de 622.9 en A y 53.2 en B). Los hiperparámetros se ajustaron con búsqueda en malla usando validación cruzada estratificada de cinco particiones sobre el conjunto de entrenamiento, con la *precisión promedio* como criterio; las mallas fueron deliberadamente pequeñas para el Modelo A. Los aprendices ajustados se combinaron en un ensamble apilado [15] con un metaaprendiz de regresión logística L2 ponderado por clases, cuyas entradas se generaron con el mismo esquema estratificado de cinco particiones. La implementación utilizó scikit-learn, XGBoost e imbalanced-learn [23–25] con los modelos base RF [26] y ET [27].

Las curvas ROC y de precisión–sensibilidad (PR) [5,28] y el AUC y la AP se calcularon a partir de las probabilidades predichas de la clase positiva, mientras que el reporte de clasificación y la matriz de confusión usaron el umbral de decisión predeterminado de 0.5. Dado que solo 8 muertes caen en el conjunto de prueba del Modelo A, la evidencia principal para este modelo es la validación cruzada estratificada de cinco particiones sobre los 25,736 ingresos, reportada como media ± desviación estándar para AUC, AP, sensibilidad, F1 y exactitud balanceada [29]. Los criterios formales de tamaño de muestra para modelos de predicción dependen del número de predictores candidatos, de la prevalencia del desenlace y del desempeño esperado [30]; con 41 eventos y 89 predictores candidatos (alrededor de 0.5 eventos por predictor), es poco probable que el Modelo A los cumpla, lo que es una razón adicional para tratar sus resultados como exploratorios. La validación cruzada reajusta las configuraciones ya ajustadas sobre el conjunto completo de datos; por tanto, sus estimaciones son ligeramente optimistas, pues los hiperparámetros se seleccionaron en la partición de entrenamiento. Como análisis de sensibilidad, SMOTE (estrategia de muestreo 0.2, $k = 5$) se ubicó dentro de cada partición de entrenamiento de un *pipeline* para evitar fugas hacia las particiones de validación. Para el Modelo B, el ensamble apilado se evaluó además sobre el subconjunto de hospitalizaciones por parto del conjunto de prueba, sin reentrenar. El estudio sigue la guía de reporte TRIPOD+AI en lo aplicable [31] ([**PENDIENTE:** adjuntar la lista de verificación TRIPOD+AI como material suplementario]).

3.6. Análisis adicionales

Cinco análisis adicionales complementan la evaluación principal. (i) *Validación cruzada para el Modelo B*: el mismo protocolo estratificado de cinco particiones aplicado al Modelo A se aplicó al Modelo B, de modo que ambos desenlaces se evalúan con la misma evidencia principal; una variante con SMOTE se ejecutó de la misma manera. (ii) *Modelo A sin grupos diagnósticos*: el Modelo A se reevaluó mediante validación cruzada tras retirar los 26 indicadores de grupos diagnósticos, conservando los hiperparámetros ajustados, de modo que su conjunto de predictores coincida con el del Modelo B. (iii) *Calibración y estratificación del riesgo*: se utilizaron las probabilidades fuera de partición (*out-of-fold*) del ensamble apilado sobre toda la cohorte para calcular el puntaje de Brier [32] y su habilidad relativa a un modelo que predice la prevalencia, la razón entre la probabilidad media predicha y la prevalencia observada, una curva de confiabilidad con intervalos por cuantiles [33] y tablas de "marcar el x% superior" con sensibilidad, valor predictivo positivo y *lift*. Las bandas de riesgo se definieron a partir de los percentiles de probabilidad del propio modelo (bajo: por debajo del percentil 80; moderado: del 80 al 95; alto: 5% superior), porque los puntos de corte fijos carecen de sentido con estas prevalencias, y se calcularon intervalos de confianza del 95% mediante *bootstrap* (500 remuestreos). (iv) *Explicabilidad*: se calcularon valores TreeSHAP [34,35] del aprendiz base XGBoost ajustado sobre el conjunto de prueba del Modelo B. (v) *Auditoría por subgrupos*: el desempeño en el conjunto de prueba del ensamble apilado del Modelo B se describió por grupo étnico, seguro de salud, cuartil de edad, estancia en UCI e ingreso por parto frente a no parto, reportando el AUC con intervalos de confianza *bootstrap* solo para los subgrupos con al menos 10 ingresos positivos y 10 negativos. Auditar el desempeño por subgrupos responde a preocupaciones documentadas de que los algoritmos pueden reproducir o amplificar inequidades en la atención en salud [36,37].

4. Resultados

4.1. Cohortes y desenlaces

La Tabla 2 compara las dos tareas de predicción. El Modelo B tiene 11.6 veces más eventos que el Modelo A y 95 positivos, en lugar de 8, en el conjunto de prueba.

Tabla 2. Comparación de las dos tareas de predicción (los mismos 25,736 ingresos).

	Modelo A (mortalidad)	**Modelo B (MMG)**
Ingresos positivos	41 (0.159%)	475 (1.846%)
Positivos en la división de entrenamiento / prueba	33 / 8	380 / 95
Predictores	89 (incl. 26 grupos diagnósticos)	65 (sin grupos diagnósticos)
Peso de la clase positiva (XGBoost)	622.9	53.2
Positivos retenidos tras el manejo de valores atípicos	41 de 41	475 de 475

4.2. Análisis descriptivo de la morbilidad materna grave

Los 20 indicadores de CDC/HRSA se observaron al menos una vez. La Tabla 3 enumera el número de ingresos por indicador. Los indicadores renales fueron la categoría más frecuente (180 ingresos con al menos un indicador renal), seguidos de hemorragia (131), respiratorios (89), otros médicos (77), sepsis (62), cardiacos (61) y otros obstétricos (56). Cuando cada ingreso con MMG se asignó a la categoría con más indicadores, las categorías primarias fueron renal (132), hemorragia (115), otros médicos (71), cardiaca (52), otros obstétricos (38), respiratoria (36) y sepsis (31). La mayoría de los ingresos con MMG involucró una sola categoría clínica (364 de 475, 76.6%), mientras que 64 involucraron dos, 27 tres, 17 cuatro y 3 cinco categorías (111 ingresos, 23.4%, con más de una categoría). Los pares más frecuentes fueron respiratoria con hemorragia (42 ingresos), renal con hemorragia (37), renal con respiratoria (28), cardiaca con respiratoria (26) y hemorragia con sepsis (20) (Figura 2). La tasa de MMG fue de 184.6 por 10,000 ingresos en la cohorte ampliada y de 284.5 por 10,000 en las hospitalizaciones por parto, frente a un rango publicado de 58–88 por 10,000 partos.

Tabla 3. Ingresos por indicador de MMG de CDC/HRSA, agrupados por categoría clínica (un ingreso puede contener varios indicadores).

Categoría	**Indicador**	**Ingresos**
Cardiaca	Edema pulmonar / insuficiencia cardiaca aguda	45
	Conversión del ritmo cardiaco	8
	Infarto agudo de miocardio	7
	Paro cardiaco / fibrilación ventricular	7
	Aneurisma	5
	Insuficiencia / paro cardiaco durante cirugía o procedimiento	1
Hemorragia	Choque	72
	Coagulación intravascular diseminada	61
	Histerectomía	41
Otras médicas	Trastornos cerebrovasculares puerperales	55
	Anemia falciforme con crisis	23
Otras obstétricas	Embolia gaseosa y trombótica	33
	Eclampsia	16
	Embolia de líquido amniótico	4
	Complicaciones graves de la anestesia	4
Renal	Insuficiencia renal aguda	180
Respiratoria	Síndrome de dificultad respiratoria aguda	66
	Ventilación	51
	Traqueostomía temporal	1
Sepsis	Sepsis	62

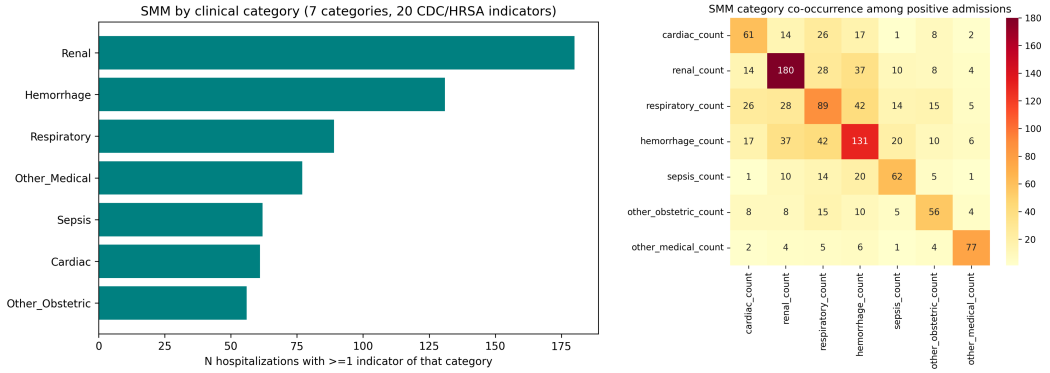


Figura 2. Ingresos con MMG por categoría clínica (izquierda) y coocurrencia de categorías entre los ingresos con MMG (derecha; la diagonal indica el número de ingresos por categoría). Las etiquetas de la figura están en inglés.

4.3. Estructura de correlación de los predictores

Diez pares de variables clínicas tuvieron $|r| \geq 0.70$ (Tabla 4), todos fisiológicamente esperables: estancia en UCI y número de estancias en UCI, las tres medidas de presión arterial, los componentes de la escala de coma de Glasgow con la Escala de Agitación–Sedación de Richmond, y hemoglobina con hematocrito. Siguiendo la política de la Sección 3, no se eliminó ninguna variable por colinealidad. El componente motor de Glasgow y la escala de Richmond se descartaron del Modelo A por varianza casi nula (valor más frecuente en más del 99% de las filas) y se conservaron en el Modelo B.

Tabla 4. Pares de variables clínicas con $|r| \geq 0.70$ (idénticos en ambos modelos).

Variable 1	**Variable 2**	*r*
Estancia en UCI	Número de estancias en UCI	0.958
Presión arterial media	Presión arterial diastólica	0.907
Apertura ocular (Glasgow)	Respuesta verbal (Glasgow)	0.891
Apertura ocular (Glasgow)	Respuesta motora (Glasgow)	0.882
Hemoglobina	Hematocrito	0.839
Presión arterial media	Presión arterial sistólica	0.833
Apertura ocular (Glasgow)	Escala de Agitación–Sedación de Richmond	0.783
Respuesta verbal (Glasgow)	Respuesta motora (Glasgow)	0.773
Respuesta verbal (Glasgow)	Escala de Agitación–Sedación de Richmond	0.754
Respuesta motora (Glasgow)	Escala de Agitación–Sedación de Richmond	0.747

4.4. Modelo A: mortalidad

La Tabla 5 y la Figura 3 muestran los resultados con validación cruzada. El ensamble apilado tuvo el AUC más alto (0.853 ± 0.078) y la mayor exactitud balanceada y sensibilidad (0.752 y 0.611), pero su F1 fue de solo 0.018, y su AP (0.164 ± 0.090) fue comparable a la de XGB y ET (0.158 y 0.151) y muy inferior a cualquier nivel clínicamente útil en términos absolutos, aunque equivale aproximadamente a cien veces la prevalencia de 0.0016. La variabilidad entre particiones fue grande (la desviación estándar de la AP llegó a 0.093 en XGB y a 0.090 en el ensamble apilado) y RF no produjo predicciones positivas con el umbral predeterminado (sensibilidad 0). LR tuvo el menor AUC y AP (0.737 y 0.023). En el conjunto de prueba (8 muertes), los valores de AUC variaron de 0.532 (RF) a 0.799 (LR), con el ensamble apilado en 0.778 y una AP de 0.089 (Tabla 7). Su matriz de confusión contenía 6 verdaderos positivos, 2 falsos negativos, 365 falsos positivos y 4,775 verdaderos negativos (sensibilidad 0.75, precisión 0.016); estas estimaciones puntuales se basan en ocho pacientes y deben leerse solo como ilustrativas.

Tabla 5. Modelo A: validación cruzada estratificada de cinco particiones (media ± DE) sobre los 25,736 ingresos (41 muertes).

Modelo	AUC	AP	Sensibilidad	F1	Exact. bal.
Random Forest	0.841 ± 0.068	0.110 ± 0.050	0.000 ± 0.000	0.000 ± 0.000	0.500 ± 0.000
XGBoost	0.810 ± 0.081	0.158 ± 0.093	0.142 ± 0.107	**0.183 ± 0.129**	0.571 ± 0.054
Extra Trees	0.830 ± 0.070	0.151 ± 0.061	0.050 ± 0.061	0.084 ± 0.104	0.525 ± 0.031
Regresión logística	0.737 ± 0.077	0.023 ± 0.019	0.439 ± 0.125	0.020 ± 0.007	0.683 ± 0.059
Apilamiento	**0.853 ± 0.078**	**0.164 ± 0.090**	**0.611 ± 0.115**	0.018 ± 0.003	**0.752 ± 0.050**

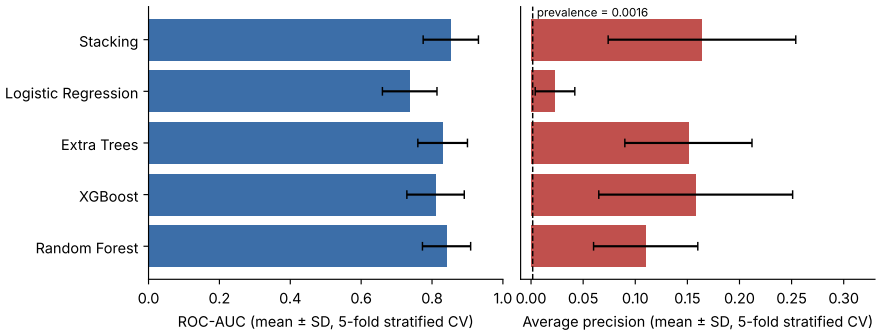


Figura 3. Modelo A: AUC y precisión promedio con validación cruzada, con desviaciones estándar. La línea discontinua marca la prevalencia del desenlace (41/25,736). Las etiquetas de la figura están en inglés.

4.5. Análisis de sensibilidad con sobremuestreo (Modelo A)

Añadir SMOTE dentro de cada partición de entrenamiento aumentó el AUC de los cinco modelos (p. ej., apilamiento de 0.853 a 0.882, XGB de 0.810 a 0.840, ET de 0.830 a 0.865) y la sensibilidad de RF y XGB, pero no la del ensamble apilado (de 0.611 a 0.119) ni la de LR (de 0.439 a 0.169). La AP cambió poco en los mejores modelos (apilamiento de 0.164 a 0.173, XGB de 0.158 a 0.163, ET de 0.151 a 0.145), disminuyó en RF (de 0.110 a 0.075) y aumentó en LR (de 0.023 a 0.041) (Tabla 6, Figura 4). Los cambios en AUC y AP son todos menores que una desviación estándar, mientras que la sensibilidad del ensamble apilado cayó de forma marcada. Dado que el sobremuestreo principalmente desplaza el punto de operación en lugar de aportar información, y que la AP no mejoró más allá del ruido entre particiones, se mantuvo la ponderación de clases como opción predeterminada.

Tabla 6. Modelo A: efecto de SMOTE (estrategia de muestreo 0.2) sobre el AUC, la AP y la sensibilidad con validación cruzada de cinco particiones (valores medios).

	AUC		AP		Sensibilidad	
Modelo	Pesos	SMOTE	Pesos	SMOTE	Pesos	SMOTE
Random Forest	0.841	0.862	0.110	0.075	0.000	0.050
XGBoost	0.810	0.840	0.158	0.163	0.142	0.169
Extra Trees	0.830	0.865	0.151	0.145	0.050	0.050
Regresión logística	0.737	0.776	0.023	0.041	0.439	0.169
Apilamiento	0.853	0.882	0.164	0.173	0.611	0.119

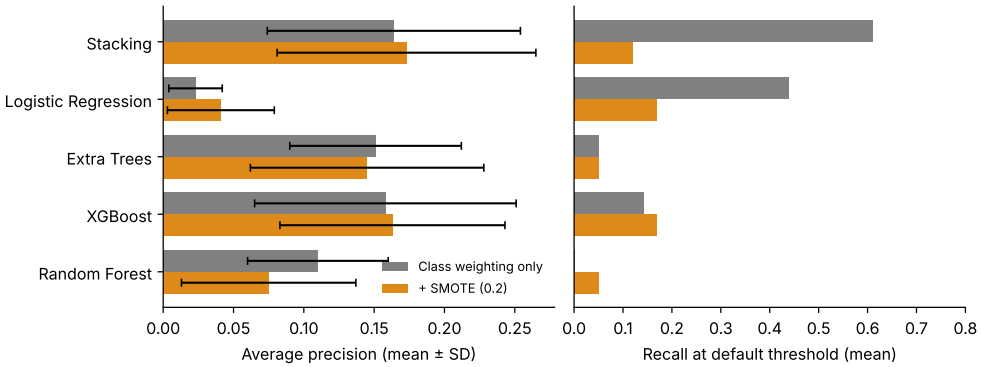


Figura 4. Modelo A: ponderación de clases frente a SMOTE en validación cruzada de cinco particiones. Las etiquetas de la figura están en inglés.

4.6. Modelo B: morbilidad materna grave

El Modelo B mostró un comportamiento mejor y mucho más estable. En el conjunto de prueba (95 casos de MMG), el ensamble apilado fue el mejor modelo tanto en AUC (0.913) como en AP (0.384), seguido de XGB (AUC 0.909, AP 0.358) y RF (AUC 0.900, AP 0.360) (Tabla 7). La AP del ensamble apilado es unas 21 veces la prevalencia en el conjunto de prueba (0.018). Con el umbral predeterminado, su matriz de confusión mostró 75 verdaderos positivos, 20 falsos negativos, 473 falsos positivos y 4,580 verdaderos negativos (sensibilidad 0.79, precisión 0.14). Restringido a los 1,802 ingresos de prueba que fueron hospitalizaciones por parto (58 casos de MMG, 3.219%), el mismo modelo alcanzó una sensibilidad de 0.78, precisión de 0.27, F1 de 0.40 para la clase positiva y una AP de 0.646 (frente a 0.384 en todo el conjunto de prueba), con una exactitud global de 0.93. La Figura 5 muestra las curvas ROC y PR del ensamble apilado para ambos modelos.

Tabla 7. Desempeño en el conjunto de prueba (probabilidades de la clase positiva): AUC y precisión promedio. Conjunto de prueba del Modelo A: 5,148 ingresos, 8 muertes; conjunto de prueba del Modelo B: 5,148 ingresos, 95 casos de MMG.

	Modelo A (mortalidad)		**Modelo B (MMG)**	
Modelo	AUC	AP	AUC	AP
Random Forest	0.532	0.046	0.900	0.360
XGBoost	0.736	0.139	0.909	0.358
Extra Trees	0.658	0.073	0.900	0.315
Regresión logística	0.799	0.150	0.889	0.339
Apilamiento	0.778	0.089	**0.913**	**0.384**

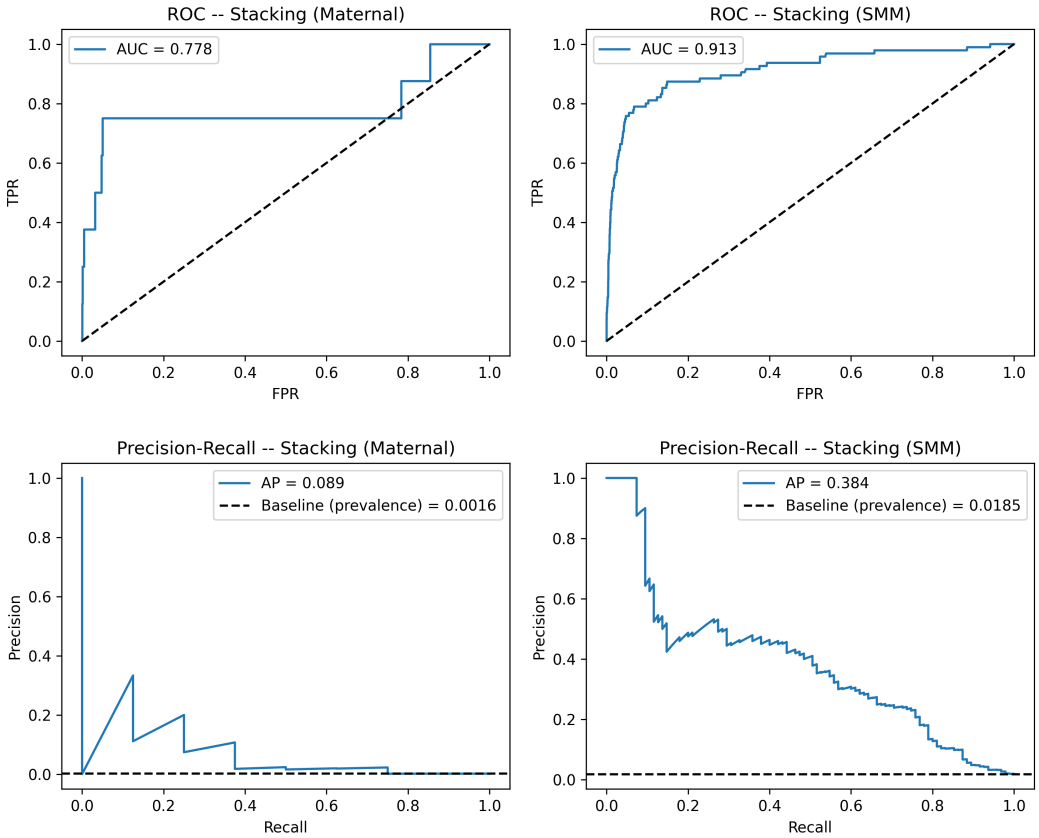


Figura 5. Curvas ROC (arriba) y de precisión–sensibilidad (abajo) del ensamble apilado en el conjunto de prueba. Izquierda: Modelo A; derecha: Modelo B. Las etiquetas de la figura están en inglés.

4.7. Importancia de los predictores

La Figura 6 muestra los 30 predictores más importantes del Random Forest ajustado para cada modelo. En el Modelo A, la edad al ingreso ocupó el primer lugar, seguida del hematocrito, la hemoglobina, el indicador de grupo diagnóstico `gdg_m13` y la creatinina. En el Modelo B, las primeras posiciones fueron ocupadas por valores de laboratorio: creatinina, glucosa, bicarbonato, magnesio y hemoglobina. Las importancias basadas en impureza describen los bosques ajustados y no constituyen evidencia de efectos causales; además, el umbral de importancia utilizado para la selección de variables se calculó pero no se aplicó, de modo que todos los predictores se conservaron en cada modelo.

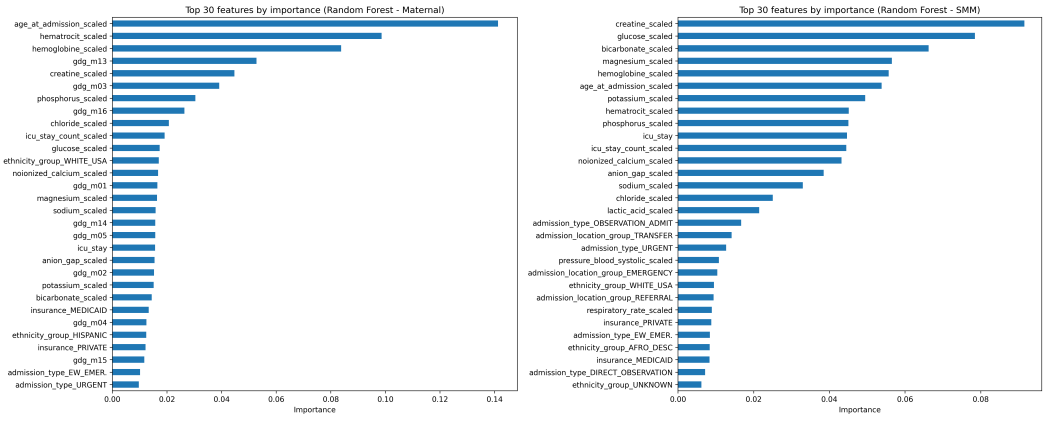


Figura 6. Las 30 variables con mayor importancia en Random Forest. Izquierda: Modelo A; derecha: Modelo B. Las etiquetas de la figura están en inglés.

4.8. Análisis adicionales

Validación cruzada para el Modelo B.

Sobre toda la cohorte (475 casos de MMG), el mismo protocolo de cinco particiones dio resultados coherentes con la evaluación en el conjunto de prueba y considerablemente menos dispersos que los del Modelo A (Tabla 8, Figura 7). El ensamble apilado tuvo el mayor AUC y la mayor AP (0.904 $\pm$ 0.020 y 0.419 $\pm$ 0.050, unas 23 veces la prevalencia), con XGBoost casi idéntico (0.901 y 0.413); las desviaciones estándar del AUC entre particiones fueron de 0.017 a 0.029, frente a 0.068 a 0.081 en el Modelo A. El ensamble apilado también fue el mejor modelo en el conjunto de prueba (AUC 0.913, AP 0.384), aunque las diferencias entre los modelos superiores son menores que una desviación estándar de la AP. El punto de operación con el umbral por defecto difirió notablemente entre modelos: el ensamble apilado y XGBoost alcanzaron una sensibilidad de 0.800 y 0.758 a costa de un F1 bajo (0.234 y 0.264), mientras que Random Forest fue más conservador (sensibilidad 0.467, F1 0.444).

Tabla 8. Modelo B: validación cruzada estratificada de cinco particiones (media $\pm$ DE) sobre los 25,736 ingresos (475 casos de MMG).

Modelo	AUC	AP	Sensibilidad	F1
Random Forest	0.890 $\pm$ 0.028	0.368 $\pm$ 0.037	0.467 $\pm$ 0.034	0.444 $\pm$ 0.032
XGBoost	0.901 $\pm$ 0.017	0.413 $\pm$ 0.038	0.758 $\pm$ 0.040	0.264 $\pm$ 0.011
Extra Trees	0.885 $\pm$ 0.023	0.359 $\pm$ 0.042	0.560 $\pm$ 0.041	0.362 $\pm$ 0.035
Regresión logística	0.876 $\pm$ 0.029	0.342 $\pm$ 0.048	0.749 $\pm$ 0.074	0.233 $\pm$ 0.018
Apilamiento	**0.904** $\pm$ 0.020	**0.419** $\pm$ 0.050	0.800 $\pm$ 0.040	0.234 $\pm$ 0.013

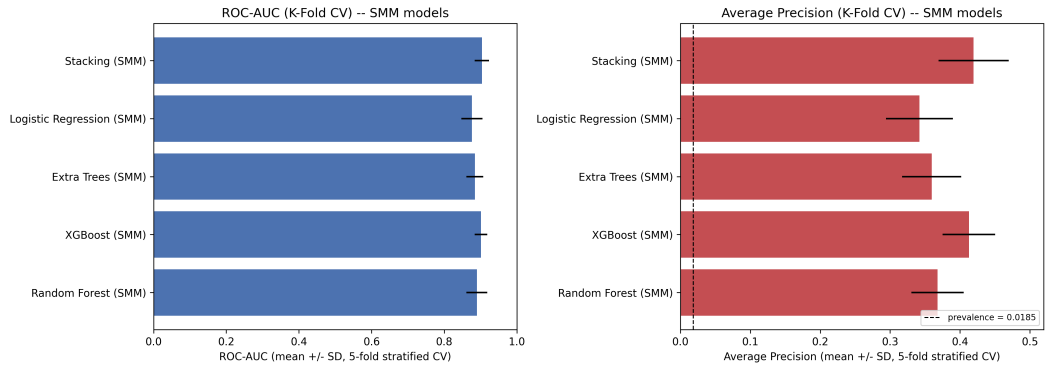


Figura 7. Modelo B: AUC y AP con validación cruzada de cinco particiones (media y desviación estándar); la línea discontinua es la prevalencia. Las etiquetas de la figura están en inglés.

Análisis de sensibilidad con sobremuestreo (Modelo B).

SMOTE tampoco mejoró las métricas basadas en precisión del Modelo B (Tabla 9, Figura 8). La AP del ensamble apilado pasó de 0.419 a 0.406 y la de XGBoost de 0.413 a 0.350, mientras que el AUC del ensamble apilado pasó de 0.904 a 0.896. Solo Random Forest (AUC de 0.890 a 0.899) y la regresión logística (AP de 0.342 a 0.357) mostraron pequeñas mejoras. SMOTE desplazó en cambio el punto de operación: la sensibilidad de XGBoost subió de 0.758 a 0.964, pero con un F1 de 0.047, es decir, se marcó casi la totalidad de los ingresos, mientras que la sensibilidad del ensamble apilado cayó de 0.800 a 0.636. Como en el Modelo A, se mantuvo la ponderación de clases como opción por defecto.

Tabla 9. Modelo B: efecto de SMOTE (estrategia de muestreo 0.2) sobre el AUC, la AP y la sensibilidad con validación cruzada de cinco particiones (valores medios).

	AUC		AP		Sensibilidad	
Modelo	Pesos	SMOTE	Pesos	SMOTE	Pesos	SMOTE
Random Forest	0.890	0.899	0.368	0.366	0.467	0.539
XGBoost	0.901	0.892	0.413	0.350	0.758	0.964
Extra Trees	0.885	0.875	0.359	0.349	0.560	0.535
Regresión logística	0.876	0.825	0.342	0.357	0.749	0.554
Apilamiento	0.904	0.896	0.419	0.406	0.800	0.636

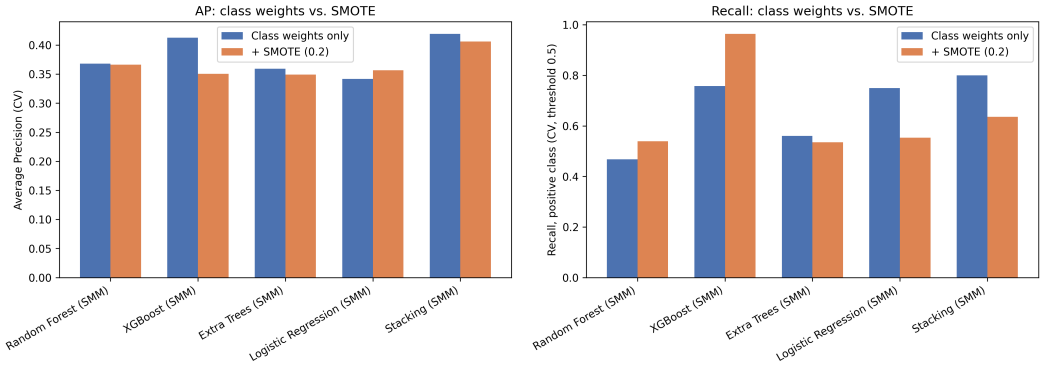


Figura 8. Modelo B: ponderación de clases frente a SMOTE con validación cruzada de cinco particiones (izquierda: AP; derecha: sensibilidad con umbral 0.5). Las etiquetas de la figura están en inglés.

Modelo A sin grupos diagnósticos.

La Tabla 10 compara el desempeño con validación cruzada del Modelo A con y sin los 26 indicadores de grupos diagnósticos. Retirarlos redujo el AUC de todos los modelos (apilamiento de 0.853 a 0.690, RF de 0.841 a 0.728, XGB de 0.810 a 0.721, ET de 0.830 a 0.781, LR de 0.737 a 0.688) y llevó la AP a 0.010–0.053 en todos los modelos (apilamiento de 0.164 a 0.012, frente a una prevalencia de 0.0016), con mayor dispersión entre particiones (la desviación estándar del AUC del apilamiento pasó de 0.078 a 0.144). En el conjunto de prueba, el ensamble apilado pasó de un AUC de 0.778 y una AP de 0.089 a 0.764 y 0.008 (ocho positivos; solo ilustrativo). Por tanto, la mayor parte de la señal discriminativa del Modelo A proviene de los grupos diagnósticos, que se derivan de los códigos CIE del propio ingreso.

Tabla 10. Modelo A: AUC y AP con validación cruzada con y sin los indicadores de grupos diagnósticos (hiperparámetros conservados; valores medios).

	AUC		AP	
Modelo	Con	Sin	Con	Sin
Random Forest	0.841	0.728	0.110	0.010
XGBoost	0.810	0.721	0.158	0.053
Extra Trees	0.830	0.781	0.151	0.024
Regresión logística	0.737	0.688	0.023	0.016
Apilamiento	0.853	0.690	0.164	0.012

Calibración y estratificación del riesgo del Modelo A.

Con las probabilidades fuera de partición del ensamble apilado sobre toda la cohorte (41 muertes), el AUC fue 0.835 (intervalo de confianza *bootstrap* del 95%: 0.754–0.904) y la AP fue 0.112 (0.037–0.243). Como es esperable tras la ponderación de clases, las probabilidades predichas fueron muy superiores a la frecuencia observada: la probabilidad media predicha

fue 0.369 frente a una prevalencia observada de 0.0016 (razón 231.7), el puntaje de Brier fue 0.152 (0.0016 para un modelo que siempre predice la prevalencia; habilidad de Brier −94.6) y la curva de confiabilidad quedó por debajo de la diagonal en todo su rango (Figura 9). Las medidas basadas en el orden no dependen de la calibración (Tabla 11). Marcar el 5% superior de los ingresos (1,287) capturó 19 de las 41 muertes (sensibilidad 0.463, intervalo de confianza del 95%: 0.303–0.615; valor predictivo positivo 0.015, 0.009–0.022; *lift* 9.3). Con bandas de riesgo basadas en percentiles, la mortalidad observada fue 0.05% en la banda baja (por debajo del percentil 80; 10 muertes entre 20,588 ingresos), 0.31% en la banda moderada (percentil 80 a 95; 12 de 3,861) y 1.48% en la banda alta (5% superior; 19 de 1,287), un gradiente de unas 30 veces entre la banda alta y la baja. En el conjunto de prueba, 5 de las 8 muertes cayeron en la banda alta, 1 en la moderada y 2 en la baja.

Tabla 11. Modelo A: tabla de "marcar el x% superior" a partir de las predicciones fuera de partición del ensamble apilado (41 muertes entre 25,736 ingresos).

x% superior marcado	Ingresos	Muertes capturadas	Sensibilidad	VPP	*Lift*
0.5%	129	10	0.244	0.0775	48.7
1%	257	13	0.317	0.0506	31.8
2%	515	15	0.366	0.0291	18.3
5%	1,287	19	0.463	0.0148	9.3
10%	2,574	24	0.585	0.0093	5.9
20%	5,147	31	0.756	0.0060	3.8

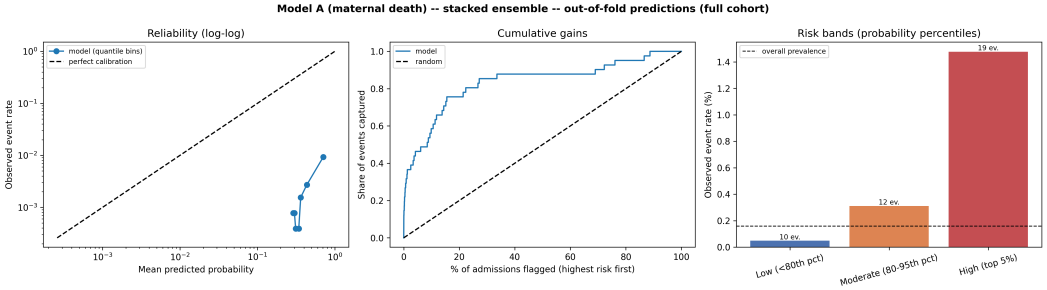


Figura 9. Modelo A, ensamble apilado, predicciones fuera de partición sobre toda la cohorte: curva de confiabilidad (escala log–log), ganancias acumuladas y mortalidad observada por banda de riesgo. Las etiquetas de la figura están en inglés.

Calibración y estratificación del riesgo del Modelo B.

Las probabilidades fuera de partición del ensamble apilado sobre toda la cohorte (475 casos de MMG) dieron un AUC de 0.902 (intervalo de confianza *bootstrap* del 95%: 0.884–0.920) y una AP de 0.396 (0.349–0.454). Las probabilidades fueron de nuevo mucho mayores que la frecuencia observada: la probabilidad media predicha fue 0.249 frente a una prevalencia de 0.0185 (razón 13.5), el puntaje de Brier fue 0.092 (0.018 para un modelo que siempre predice la prevalencia; habilidad de Brier −4.10) y la curva de confiabilidad quedó por debajo de la diagonal (Figura 10). El conjunto de prueba mostró el mismo patrón (probabilidad media predicha 0.252, razón 13.6; puntaje de Brier 0.093). Por tanto, las probabilidades deben usarse para ordenar ingresos y no como riesgos absolutos. En términos de ordenamiento (Tabla 12), marcar el 5% superior de los ingresos (1,287) capturó 324 de los 475 casos de MMG (sensibilidad 0.682, intervalo de confianza *bootstrap* del 95%: 0.643–0.719; valor predictivo positivo 0.252, 0.226–0.277; *lift* 13.6), y marcar el 1% superior (257) ya capturó 151 casos con un valor predictivo positivo de 0.588. Con bandas de riesgo basadas en percentiles, la tasa observada de MMG fue 0.34% en la banda baja (70 casos entre 20,588 ingresos), 2.10% en la banda moderada (81 de 3,861) y 25.2% en la banda alta (324 de 1,287), un gradiente de unas 74 veces entre la banda alta y la baja; la banda alta

contuvo el 68% de todos los casos y la baja el 15%. En el conjunto de prueba, 64 de los 95 casos cayeron en la banda alta (tasa observada 24.8%), 19 en la moderada (2.5%) y 12 en la baja (0.29%); la sensibilidad y el valor predictivo positivo en el 5% superior fueron 0.674 (0.589–0.780) y 0.249 (0.195–0.309). Se usaron bandas basadas en percentiles porque los puntos de corte de probabilidad (0.27 y 0.80 para las bandas moderada y alta) son específicos de este modelo y no tienen significado como riesgos absolutos.

Tabla 12. Modelo B: tabla de "marcar el x% superior" a partir de las predicciones fuera de partición del ensamble apilado (475 casos de MMG entre 25,736 ingresos).

x% superior marcado	Ingresos	Casos capturados	Sensibilidad	VPP	*Lift*
0.5%	129	79	0.166	0.612	33.2
1%	257	151	0.318	0.588	31.8
2%	515	238	0.501	0.462	25.0
5%	1,287	324	0.682	0.252	13.6
10%	2,574	372	0.783	0.145	7.8
20%	5,147	405	0.853	0.079	4.3

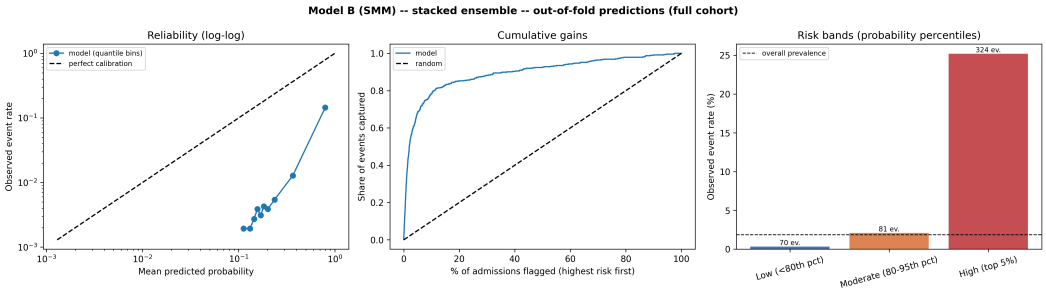


Figura 10. Modelo B, ensamble apilado, predicciones fuera de partición sobre toda la cohorte: curva de confiabilidad (escala log–log), ganancias acumuladas y tasa observada de MMG por banda de riesgo. Las etiquetas de la figura están en inglés.

Explicabilidad y auditoría por subgrupos.

Los valores SHAP absolutos medios del aprendiz base XGBoost en el conjunto de prueba fueron mayores para creatinina (0.28), glucosa (0.24), estancia en UCI (0.24), bicarbonato (0.18), ácido láctico (0.16), magnesio (0.14), edad (0.13) y hemoglobina (0.13), seguidos de hematocrito, los tipos de ingreso por observación y urgente, y los ingresos por traslado (0.08–0.09) (Figura 11). El orden concuerda con las importancias de Random Forest (valores de laboratorio renales y metabólicos en los primeros lugares) y añade la estancia en UCI y el ácido láctico. Son descripciones del modelo ajustado y no efectos causales; además, la estancia en UCI y el lactato pueden seguir al evento mórbido en lugar de precederlo, por lo que su peso debe leerse con la salvedad sobre la temporalidad que se discute más adelante.

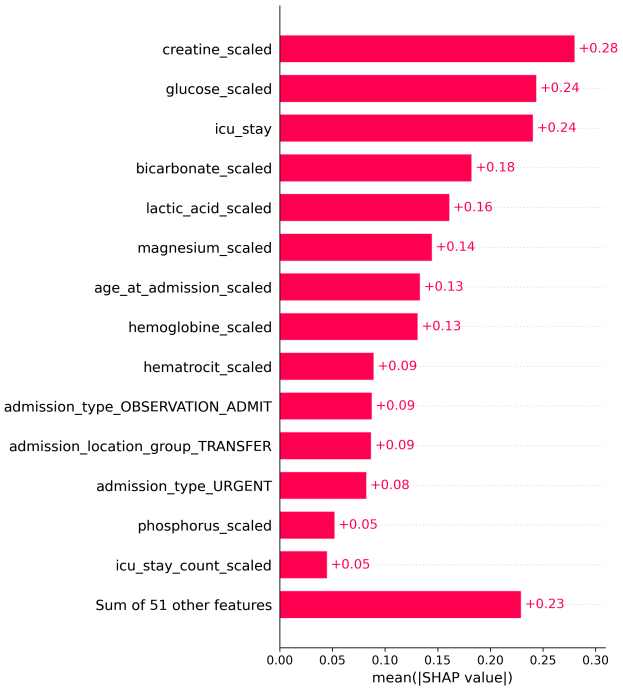


Figura 11. Modelo B: valor SHAP absoluto medio de las 15 variables más influyentes del aprendiz base XGBoost (conjunto de prueba). Los nombres de las variables son los del cuaderno; el sufijo `_scaled` indica la versión escalada de cada variable.

En el conjunto de prueba, el AUC del ensamble apilado estuvo entre 0.86 y 0.95 en casi todos los subgrupos con al menos 10 ingresos positivos (Tabla 13); los intervalos de confianza fueron amplios y se solaparon entre grupos étnicos, categorías de seguro y cuartiles de edad, por lo que no puede afirmarse ninguna diferencia entre ellos. No se evaluaron los subgrupos con menos de 10 positivos (grupos asiático, hispano, indoamericano, blanco europeo e isleño del Pacífico; Medicare, otros seguros y seguro sin clasificar). La excepción clara fueron los 94 ingresos con estancia en UCI, entre los cuales 36 (38%) fueron casos de MMG y el AUC fue 0.655 (0.539–0.767): el modelo marcó el 99% de ellos, de modo que la estancia en UCI fue por sí sola un fuerte predictor de MMG pero el modelo no separó casos de no casos dentro de este grupo. El desempeño fue similar en hospitalizaciones por parto (AUC 0.920) y no relacionadas con parto (0.913), aunque la AP fue tres veces mayor en las primeras (0.646 frente a 0.221), reflejo de su mayor prevalencia. Todas las estimaciones por subgrupo son descriptivas, se basan en una sola partición de prueba y no constituyen una evaluación formal de equidad.

Tabla 13. Modelo B: desempeño del ensamble apilado en el conjunto de prueba por subgrupo. Solo se muestran los subgrupos con al menos 10 ingresos positivos. Los grupos de edad corresponden a los cuartiles de la edad escalada, aproximadamente ≤28, 29–32, 33–36 y ≥37 años. Las etiquetas de grupo étnico son las del cuaderno.

Dimensión	Subgrupo	Ingresos	Casos de MMG	AUC (IC 95%)	AP
Grupo étnico	AFRO_DESC	1,285	28	0.866 (0.769–0.946)	0.304
	UNKNOWN	619	17	0.944 (0.865–0.984)	0.532
	WHITE_USA	2,092	39	0.921 (0.868–0.965)	0.355
Seguro	Medicaid	1,731	32	0.902 (0.820–0.967)	0.430
	Privado	3,194	60	0.923 (0.878–0.963)	0.405
Edad	≤28 años	1,312	20	0.884 (0.773–0.968)	0.351
	29–32 años	1,271	18	0.940 (0.862–0.986)	0.317
	33–36 años	1,333	29	0.953 (0.917–0.982)	0.473
	≥37 años	1,232	28	0.860 (0.763–0.949)	0.404
Estancia en UCI	Sí	94	36	0.655 (0.539–0.767)	0.609
	No	5,054	59	0.873 (0.815–0.929)	0.219
Hospitalización	Parto	1,802	58	0.920 (0.874–0.963)	0.646
	No parto	3,346	37	0.913 (0.851–0.960)	0.221

5. Discusión

La mortalidad no es un objetivo de modelamiento con este tamaño de muestra. Con 41 muertes, valores de AUC con validación cruzada de 0.74–0.85 coexistieron con AP de 0.02–0.16, con desviaciones estándar de la AP del mismo orden que las medias y con conclusiones en el conjunto de prueba sustentadas en ocho muertes. Por tanto, una clasificación de los cinco algoritmos no es confiable: por ejemplo, LR alcanzó el mejor AUC y AP en el conjunto de prueba (0.799 y 0.150) pero el menor AUC y AP con validación cruzada (0.737 y 0.023), mientras que RF tuvo el menor AUC en el conjunto de prueba (0.532) pero el segundo AUC más alto con validación cruzada (0.841). Nuestros resultados respaldan la recomendación de reportar métricas de precisión–sensibilidad y la dispersión por partición para desenlaces raros [4,5].

La MMG es un sustituto más estable, pero ruidoso. Una clase positiva once veces mayor produjo valores de AUC en el conjunto de prueba de 0.889–0.913 con una dispersión estrecha entre algoritmos, un ensamble apilado que fue el mejor tanto en AUC como en AP en el conjunto de prueba y con validación cruzada (0.904 ± 0.020 y 0.419 ± 0.050, con desviaciones estándar del AUC entre particiones de aproximadamente una cuarta parte de las del Modelo A), y un balance precisión–sensibilidad que puede discutirse clínicamente. En términos de ordenamiento, el 5% superior de los ingresos contuvo el 68% de los casos de MMG con un valor predictivo positivo de 0.25 (*lift* 13.6). Deben señalarse con claridad dos limitaciones. Primero, la etiqueta de MMG se basa en CIE; la codificación CIE-10 mostró baja sensibilidad y bajo valor predictivo positivo en un estudio de validación con historias clínicas [11], de modo que nuestros positivos son una aproximación administrativa, y el modelo podría aprender en parte patrones de codificación y de intensidad de la atención. Esto también probablemente explica la alta tasa de MMG en las hospitalizaciones por parto. Segundo, los principales predictores del Modelo B fueron creatinina, glucosa, bicarbonato y magnesio, relacionados con el trastorno renal y metabólico; dado que la insuficiencia renal aguda es el indicador más frecuente (180 ingresos), parte de la señal refleja anomalías de laboratorio que coocurren con la definición del desenlace en lugar de anticiparlo. Usar el valor más temprano disponible mitiga, pero no elimina, esta preocupación, y no se impuso una temporalidad prospectiva de los predictores respecto del evento. El análisis SHAP y la auditoría por subgrupos apuntan en la misma dirección: la estancia en UCI y el ácido láctico figuraron entre los predictores más influyentes, y el AUC fue el menor (0.655) en los 94 ingresos de prueba con estancia en UCI, entre los cuales 36 fueron casos

de MMG y el modelo marcó el 99%; por tanto, la estancia en UCI es en sí misma un fuerte marcador de MMG, pero el modelo no separa casos de no casos entre los pacientes críticos. Las diferencias entre grupos étnicos, de seguro y de edad no se distinguieron del ruido muestral (intervalos solapados basados en 17 a 60 positivos por subgrupo), y no puede hacerse ninguna afirmación sobre equidad a partir de ellas.

Sobremuestreo y política de valores atípicos. SMOTE no mejoró las métricas basadas en precisión en ninguno de los dos modelos (AP del apilamiento de 0.164 a 0.173 en el Modelo A y de 0.419 a 0.406 en el Modelo B) y desplazó el punto de operación de forma impredecible (sensibilidad de XGBoost en el Modelo B de 0.758 a 0.964 con un F1 de 0.047), en línea con la evidencia de que las correcciones del desbalance pueden perjudicar la calibración y no necesariamente mejoran la discriminación [17]. Reemplazar la eliminación de filas por la winsorización preservó todos los casos positivos; conservarlos importa más que la pulcritud geométrica de la distribución de las variables, ya que eliminar valores extremos de laboratorio remueve precisamente a los pacientes más graves.

Limitaciones. (i) Datos de un solo centro y sin validación externa. (ii) El Modelo A incluye los 26 indicadores de grupos diagnósticos mientras que el Modelo B los excluye; los dos modelos no son, por tanto, estrictamente comparables en sus conjuntos de predictores. Retirar los indicadores del Modelo A redujo su AUC con validación cruzada de 0.853 a 0.690 y su AP de 0.164 a 0.012, de modo que su desempeño con los grupos depende de variables derivadas de los diagnósticos del propio ingreso, que podrían reflejar el curso clínico que conduce a la muerte en lugar de anticiparlo. (iii) Los valores de imputación y los escaladores se ajustaron antes de la división entrenamiento/prueba, y la validación cruzada reajusta hiperparámetros ajustados sobre la partición de entrenamiento, lo que puede hacer que las estimaciones sean ligeramente optimistas. (iv) La etiqueta de MMG basada en CIE y las variables de laboratorio y de UCI pueden ser en parte concurrentes con el evento (no se impuso la temporalidad de los predictores respecto del evento). (v) El desenlace de mortalidad captura solo las muertes registradas por el hospital; las muertes posteriores al alta no se observan. (vi) Las métricas con el umbral predeterminado de 0.5 se muestran por transparencia; la calibración se evaluó pero no se corrigió: las probabilidades fueron 13.5 veces (Modelo B) y 232 veces (Modelo A) mayores que la prevalencia observada, no se optimizó el umbral, y las probabilidades predichas no deben interpretarse como riesgos absolutos, ya que la ponderación de clases y los ensambles de árboles producen, como se sabe, probabilidades mal calibradas [17,33,38]. (vii) MIMIC-IV no es un registro obstétrico y puede diferir de la población de los servicios obstétricos de otros sistemas de salud. Los modelos son prototipos de investigación y no deben orientar decisiones clínicas individuales.

6. Implicaciones y trabajo futuro

Implicaciones para la práctica. Los resultados no respaldan el uso de ninguno de los modelos para decisiones individuales. Sí indican cómo debería diseñarse una herramienta de riesgo materno: como una clasificación de ingresos para revisión y no como un clasificador con un umbral predeterminado, con la proporción de ingresos señalados elegida por un panel clínico a la luz del balance entre sensibilidad y precisión, y con los riesgos absolutos recalibrados antes de mostrarse. Cualquier punto de operación o acción desencadenada por una herramienta de este tipo en la atención obstétrica requiere validación por un responsable humano autorizado.

Vigilancia en lugar de predicción. Dado que las categorías de MMG son clínicamente distintas (renal, hemorrágica, respiratoria y otras), y que casi una cuarta parte de los ingresos con MMG involucra más de una categoría, un hospital podría usar las mismas

variables para monitorear la carga de MMG por categoría y para revisar casos, aunque la predicción individual siga siendo imperfecta.

Trabajo futuro. De las limitaciones se derivan cinco direcciones. (i) Validación externa en otras cohortes hospitalarias, en particular servicios obstétricos, para comprobar si la señal impulsada por el laboratorio se generaliza. (ii) Validación de la etiqueta de MMG basada en CIE frente a la revisión de historias clínicas en una muestra, para estimar su sensibilidad y valor predictivo positivo reales en esta cohorte. (iii) Restricción de los predictores a valores registrados antes del evento, lo que convertiría el modelo de MMG en un verdadero modelo de alerta temprana. (iv) Recalibración del ensamble apilado (el presente análisis solo documenta su descalibración) y análisis de curvas de decisión [39]. (v) Un modelo multiclase secundario que prediga la categoría primaria de MMG entre los ingresos positivos, lo que responde a la pregunta clínicamente distinta de qué complicación es más probable una vez que ocurre la MMG.

7. Conclusiones

En 25,736 ingresos obstétricos de MIMIC-IV, la muerte materna registrada en el ámbito hospitalario (41 eventos) no pudo modelarse con una precisión confiable, mientras que la MMG (475 eventos) permitió una evaluación estable, con un ensamble apilado que alcanzó un AUC de 0.913 y una AP de 0.384 en el conjunto de prueba, confirmadas por validación cruzada (0.904 y 0.419); el 5% superior de los ingresos según la probabilidad predicha contuvo el 68% de los casos de MMG. La discriminación aparente para mortalidad dependió en gran parte de los indicadores de grupos diagnósticos, las probabilidades de ambos modelos no estuvieron calibradas y el desempeño fue menor entre los ingresos con estancia en UCI. La ponderación de clases fue preferible a SMOTE, y la winsorización protegió a los casos positivos de ser eliminados. El trabajo futuro debería validar estos modelos en cohortes independientes, recalibrarlos y definir umbrales para un caso de uso de apoyo a la decisión, y evaluar la tarea multiclase secundaria de predecir la categoría de MMG.

Contribuciones de los autores: Conceptualización, E.G.J. y J.D.M.D.; metodología, E.G.J.; software, E.G.J.; validación, E.G.J. y J.D.M.D.; análisis formal, E.G.J.; curación de datos, E.G.J.; redacción—preparación del borrador original, E.G.J.; redacción—revisión y edición, J.D.M.D.; supervisión, J.D.M.D. Todos los autores han leído y aceptado la versión publicada del manuscrito. **[PENDIENTE:** confirmar las contribuciones]

Financiación: Esta investigación fue apoyada por el programa Becas de Excelencia Doctoral del Bicentenario, financiado por el Fondo de Ciencia, Tecnología e Innovación del Sistema General de Regalías (FCTeI-SGR) y administrado por el Ministerio de Ciencia, Tecnología e Innovación (Minciencias) de Colombia. Este apoyo se brindó a través del BPIN 2020000100287, por medio de la Universidad del Norte, Barranquilla, Colombia, como institución ejecutora.

Declaración del Comité de Ética Institucional: Se renunció a la revisión y aprobación ética de este estudio debido a la naturaleza retrospectiva, totalmente anonimizada y de uso secundario de la base de datos MIMIC-IV. La recolección original y la anonimización de los datos fueron revisadas y aprobadas por el Comité de Ética Institucional (IRB) del Beth Israel Deaconess Medical Center (BIDMC), que concedió una exención del consentimiento informado para la creación y el intercambio de la base de datos [13].

Declaración de consentimiento informado: El Comité de Ética Institucional del Beth Israel Deaconess Medical Center renunció al consentimiento de los pacientes para la recolección original de la base de datos MIMIC-IV, debido a su naturaleza retrospectiva y totalmente anonimizada [13]. Los autores no reclutaron directamente a ningún participante.

Declaración de disponibilidad de datos: Los datos clínicos utilizados en este estudio están disponibles en la base de datos MIMIC-IV, pero existen restricciones para su disponibilidad: se emplearon bajo un acuerdo de uso de datos y, por lo tanto, no pueden redistribuirse públicamente. Los datos están disponibles a través de PhysioNet [14] para cualquier investigador que complete la capacitación requerida y firme el Acuerdo de Uso de Datos de Salud con Credenciales de PhysioNet (https://physionet.org/content/mimiciv/). Los scripts SQL y los cuadernos para la extracción de la cohorte, el preprocesamiento y el modelamiento están disponibles en **[PENDIENTE:** insertar la URL del repositorio público].

Agradecimientos: Los autores agradecen al equipo de MIMIC-IV del Laboratorio de Fisiología Computacional (MIT) y al Beth Israel Deaconess Medical Center por mantener y proporcionar acceso abierto a la base de datos. **[PENDIENTE:** añadir otros agradecimientos, p. ej., a los revisores clínicos de la agrupación diagnóstica]

Conflictos de interés: Los autores declaran no tener conflictos de interés. **[PENDIENTE:** confirmar; el primer autor está empleado en una empresa privada sin relación con este estudio—indicarlo si la revista lo exige]

Abreviaturas

AA	Aprendizaje automático (*machine learning*)
AP	Precisión promedio (*average precision*)
AUC	Área bajo la curva característica operativa del receptor
BIDMC	Beth Israel Deaconess Medical Center
CDC	Centros para el Control y la Prevención de Enfermedades
CIE	Clasificación Internacional de Enfermedades
ET	Extra Trees
FAD	Datos federalmente disponibles (*Federally Available Data*)
HRSA	Administración de Recursos y Servicios de Salud
LR	Regresión logística
MIMIC	Medical Information Mart for Intensive Care
MMG	Morbilidad materna grave (SMM, *severe maternal morbidity*)
PR	Precisión–sensibilidad (*precision–recall*)
RF	Random Forest
RIC	Rango intercuartílico
ROC	Característica operativa del receptor
SMOTE	Técnica de sobremuestreo de la minoría sintética
UCI	Unidad de cuidados intensivos
VC	Validación cruzada
VPP	Valor predictivo positivo
XGB	XGBoost (*Extreme Gradient Boosting*)

Referencias

1. World Health Organization. Trends in maternal mortality 2000 to 2020: estimates by WHO, UNICEF, UNFPA, World Bank Group and UNDESA/Population Division. Technical report, World Health Organization, Geneva, 2023.
2. Kassebaum, N.J.; et al. Global, regional, and national levels of maternal mortality, 1990–2015: a systematic analysis for the Global Burden of Disease Study 2015. *The Lancet* **2016**, *388*, 1775–1812.
3. Say, L.; Chou, D.; Gemmill, A.; Tunçalp, Ö.; Moller, A.B.; Daniels, J.; Gülmezoglu, A.M.; Temmerman, M.; Alkema, L. Global causes of maternal death: a WHO systematic analysis. *The Lancet Global Health* **2014**, 2, e323–e333. https://doi.org/10.1016/S2214-109X(14)70227-X.
4. Marshall, B.D.L. Outcome class imbalance and rare events: An underappreciated complication for overdose risk prediction modeling. *Addiction* **2023**, *118*, 1167–1174. https://doi.org/10.1111/add.16133.
5. Saito, T.; Rehmsmeier, M. The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. *PLoS ONE* **2015**, *10*, e0118432. https://doi.org/10.1371/journal.pone.0118432.
6. Say, L.; Souza, J.P.; Pattinson, R.C. Maternal near miss—towards a standard tool for monitoring quality of maternal health care. *Best Practice & Research Clinical Obstetrics & Gynaecology* **2009**, *23*, 287–296. https://doi.org/10.1016/j.bpobgyn.2009.01.007.

7. Centers for Disease Control and Prevention. Severe Maternal Morbidity in the United States. https://www.cdc.gov/maternal-infant-health/php/severe-maternal-morbidity/, 2023.
8. Health Resources and Services Administration, Maternal and Child Health Bureau. Federally Available Data (FAD) Resource Document. https://mchb.tvisdata.hrsa.gov/Home/Resources, 2023.
9. Callaghan, W.M.; Creanga, A.A.; Kuklina, E.V. Severe Maternal Morbidity Among Delivery and Postpartum Hospitalizations in the United States. *Obstetrics & Gynecology* **2012**, *120*, 1029–1036. https://doi.org/10.1097/AOG.0b013e31826d60c5.
10. Clapp, M.A.; Perlis, R.H.; et al. Prenatal diagnosis codes predict maternal morbidity, aid in risk stratification. *Journal of Perinatology* **2021**.
11. Boulet, S.L.; Stanhope, K.K.; Valdez-Sinon, A.N.; Vuncannon, D.; Preslar, J.; Bergbower, H.; Gray, B.; Gathoo, A.; Hansen, N.; Andre, K.; et al. Validation of ICD-10 Codes for Severe Maternal Morbidity at Delivery in a Public Hospital. *Epidemiology* **2024**, *35*, 506–511. https://doi.org/10.1097/EDE.0000000000001743.
12. Johnson, A.E.W.; Pollard, T.J.; Shen, L.; Lehman, L.w.H.; Feng, M.; Ghassemi, M.; Moody, B.; Szolovits, P.; Celi, L.A.; Mark, R.G. MIMIC-III, a freely accessible critical care database. *Scientific Data* **2016**, *3*, 160035. https://doi.org/10.1038/sdata.2016.35.
13. Johnson, A.E.W.; Bulgarelli, L.; Shen, L.; Gayles, A.; Shammout, A.; Horng, S.; Pollard, T.J.; Hao, S.; Moody, B.; Gow, B.; et al. MIMIC-IV, a freely accessible electronic health record dataset. *Scientific Data* **2023**, *10*, 1.
14. Goldberger, A.L.; Amaral, L.A.N.; Glass, L.; Hausdorff, J.M.; Ivanov, P.C.; Mark, R.G.; Mietus, J.E.; Moody, G.B.; Peng, C.K.; Stanley, H.E. PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals. *Circulation* **2000**, *101*, e215–e220.
15. Wolpert, D.H. Stacked generalization. *Neural Networks* **1992**, *5*, 241–259.
16. Hastie, T.; Tibshirani, R.; Friedman, J. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2 ed.; Springer: New York, NY, 2009.
17. van den Goorbergh, R.; van Smeden, M.; Timmerman, D.; Van Calster, B. The harm of class imbalance corrections for risk prediction models: illustration and simulation using logistic regression. *Journal of the American Medical Informatics Association* **2022**, *29*, 1525–1534. https://doi.org/10.1093/jamia/ocac093.
18. Vasudevan, L.; Kibria, M.G.; Kucirka, L.M.; Shieh, K.; Wei, M.; Masoumi, S.; Balasubramanian, S.; Victor, A.; Conklin, J.L.; Gurcan, M.N.; et al. Machine Learning Models to Predict Risk of Maternal Morbidity and Mortality From Electronic Medical Record Data: Scoping Review. *Journal of Medical Internet Research* **2025**, *27*, e68225. https://doi.org/10.2196/68225.
19. Gutiérrez Jiménez, E.; Márquez Díaz, J.D. Artificial Intelligence for Neonatal and Perinatal Mortality Prevention: A Systematic Review of Machine Learning and Deep Learning Applications. *Healthcare* **2026**, *14*, 2339. https://doi.org/10.3390/healthcare14152339.
20. Gao, C.; Osmundson, S.; Yan, X.; Edwards, D.V.; Malin, B.A.; Chen, Y. Learning to Identify Severe Maternal Morbidity from Electronic Health Records. *Studies in Health Technology and Informatics* **2019**, *264*, 143–147.
21. Li, Q.; Alfonso, Y.N.; Wolfson, C.; Aziz, K.B.; Creanga, A.A. Leveraging Machine Learning to Predict and Assess Disparities in Severe Maternal Morbidity in Maryland. *Healthcare* **2025**, *13*, 284. https://doi.org/10.3390/healthcare13030284.
22. Nebraska Department of Health and Human Services, Division of Public Health, Office of Maternal and Child Health Epidemiology. Severe Maternal Morbidity Report 2017–2021. Technical report, Nebraska DHHS, 2024.
23. Pedregosa, F.; Varoquaux, G.; Gramfort, A.; Michel, V.; Thirion, B.; Grisel, O.; Blondel, M.; Prettenhofer, P.; Weiss, R.; Dubourg, V.; et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research* **2011**, *12*, 2825–2830.
24. Chen, T.; Guestrin, C. XGBoost: A Scalable Tree Boosting System. In Proceedings of the Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. ACM, 2016, pp. 785–794.
25. Chawla, N.V.; Bowyer, K.W.; Hall, L.O.; Kegelmeyer, W.P. SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research* **2002**, *16*, 321–357.
26. Breiman, L. Random Forests. *Machine Learning* **2001**, *45*, 5–32.
27. Geurts, P.; Ernst, D.; Wehenkel, L. Extremely Randomized Trees. *Machine Learning* **2006**, *63*, 3–42. https://doi.org/10.1007/s10994-006-6226-1.
28. Fawcett, T. An introduction to ROC analysis. *Pattern Recognition Letters* **2006**, *27*, 861–874.
29. Arlot, S.; Celisse, A. A survey of cross-validation procedures for model selection. *Statistics Surveys* **2010**, *4*, 40–79.
30. Riley, R.D.; Ensor, J.; Snell, K.I.E.; Harrell, F.E.; Martin, G.P.; Reitsma, J.B.; Moons, K.G.M.; Collins, G.; van Smeden, M. Calculating the sample size required for developing a clinical prediction model. *BMJ* **2020**, *368*, m441. https://doi.org/10.1136/bmj.m441.
31. Collins, G.S.; Moons, K.G.M.; Dhiman, P.; et al. TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ* **2024**, *385*, e078378. https://doi.org/10.1136/bmj-2023-078378.
32. Brier, G.W. Verification of forecasts expressed in terms of probability. *Monthly Weather Review* **1950**, *78*, 1–3.
33. Van Calster, B.; McLernon, D.J.; van Smeden, M.; Wynants, L.; Steyerberg, E.W. Calibration: the Achilles heel of predictive analytics. *BMC Medicine* **2019**, *17*, 230. https://doi.org/10.1186/s12916-019-1466-7.

34. Lundberg, S.M.; Lee, S.I. A unified approach to interpreting model predictions. In Proceedings of the Advances in Neural Information Processing Systems 30 (NeurIPS), 2017, pp. 4765–4774.
35. Lundberg, S.M.; Erion, G.; Chen, H.; DeGrave, A.; Prutkin, J.M.; Nair, B.; Katz, R.; Himmelfarb, J.; Bansal, N.; Lee, S.I. From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence* **2020**, *2*, 56–67. https://doi.org/10.1038/s42256-019-0138-9.
36. Obermeyer, Z.; Powers, B.; Vogeli, C.; Mullainathan, S. Dissecting racial bias in an algorithm used to manage the health of populations. *Science* **2019**, *366*, 447–453. https://doi.org/10.1126/science.aax2342.
37. Rajkomar, A.; Hardt, M.; Howell, M.D.; Corrado, G.; Chin, M.H. Ensuring fairness in machine learning to advance health equity. *Annals of Internal Medicine* **2018**, *169*, 866–872. https://doi.org/10.7326/M18-1990.
38. Niculescu-Mizil, A.; Caruana, R. Predicting good probabilities with supervised learning. In Proceedings of the Proceedings of the 22nd International Conference on Machine Learning (ICML). ACM, 2005, pp. 625–632.
39. Vickers, A.J.; Elkin, E.B. Decision curve analysis: a novel method for evaluating prediction models. *Medical Decision Making* **2006**, *26*, 565–574. https://doi.org/10.1177/0272989X06295361.